

Klasifikacija srčanih oboljenja primenom MLP i SMOTE

Nevena Đorđević 2022/0052 · Duboko učenje i neuronske mreže · Binarna klasifikacija na osnovu kliničkih parametara pacijenta

Motivacija

Kardiovaskularne bolesti su **vodeći uzrok smrtnosti** u svetu. Pravovremena identifikacija pacijenata sa povišenim rizikom omogućava ranu intervenciju i bolje ishode lečenja.

Ključna metrika

Recall

U medicinskoj dijagnostici cilj je **minimizovati lažno negativne** nalaze — pacijenta koji ima bolest, a model ga proglasi zdravim.



Heart Disease Cleveland UCI

Izvor: Cleveland Clinic Foundation · UCI Machine Learning Repository

Uzoraka

297

Atributa

13

Ciljna klasa

2

0 = bez oboljenja · 1 = prisutno

Zašto baš Cleveland dataset?

- Jedan od **najcitiranijih** medicinskih benchmark skupova u literaturi
- Omogućava **direktno poređenje** rezultata sa postojećim istraživanjima
- Sadrži **medicinski relevantne** kliničke attribute (godine, pol, holesterol, EKG...)
- Dovoljno mali da omogući **detaljnu analizu** ponašanja modela i hiperparametara

Prednosti vs. ograničenja

- + Široko prihvaćen u akademskoj zajednici
- + Bez nedostajućih vrednosti
- + Klasično medicinsko obeležje
- Mali broj uzoraka (297)
- Blago neuravnotežene klase
- Ograničena generalizacija

Od sirovih podataka do treninga

Eksplorativna analiza (EDA)

Šta smo pogledali

- Pregled prvih redova — `head()`
- Struktura i tipovi — `info()`
- Deskriptivna statistika — `describe()`
- Provera duplikata i nedostajućih vrednosti
- Distribucija ciljnih klasa (0 vs. 1)
- Korelaciona matrica atributa

Nalaz: dataset ne sadrži nedostajuće vrednosti niti duplikate — spreman za dalju obradu.

Pipeline preprocesiranja

Četiri koraka

1

Razdvajanje X i y

atributi (13) odvojeno od ciljne promenljive

2

Train / test podela

stratifikovana podela radi očuvanja distribucije klasa

3

Standardizacija — **StandardScaler**

$\mu = 0$, $\sigma = 1$ za sve numeričke attribute

4

SMOTE — samo na trening skupu

balansiranje manjinske klase pre ulaska u model

SMOTE — sintetičko balansiranje klasa

Synthetic Minority Over-sampling Technique — generiše nove sintetičke uzorke manjinske klase umesto pukog dupliranja

Kako radi

Interpolacija u prostoru atributa

- Za svaki uzorak x iz manjinske klase pronađe se **k najbližih suseda** iste klase ($k = 5$)
- Nasumično se izabere jedan sused x_{nn}
- Sintetička tačka se generiše kao: $x_{new} = x + \lambda \cdot (x_{nn} - x)$, gde je $\lambda \in [0, 1]$
- Postupak se ponavlja dok klase ne postanu uravnotežene

⚠ **Važno:** SMOTE se primenjuje **isključivo na trening skupu**. Primena pre podele dovela bi do curenja informacija u test skup.

Pre vs. posle SMOTE

Distribucija trening skupa

PRE SMOTE — NEURAVNOTEŽENO

~129



Klasa 0 · zdravi

~108



Klasa 1 · oboleli

POSLE SMOTE — URAVNOTEŽENO

~129




Klasa 0

~129



Klasa 1 (+sintetički)

MLP arhitektura: 13 → 32 → 16 → 1



Hiperparametri

Optimizer
Adam
Adaptivni gradijent

Learning rate
0.001
Default Adam vrednost

Loss
Binary Crossentropy
Za binarnu klasifikaciju

Batch size
16
Mini-batch trening

Epoha
50
Sa validation split

Validation split
0.2
20% trening skupa

TensorFlow / Keras · 8 konfiguracija

Trening setup

Reproduktibilan tok

Framework

TensorFlow · Keras

Random seed

42

fiksiran radi reproduktibilnosti

Praćene metrike

- accuracy
- val_accuracy
- loss
- val_loss

Model je konvergirao stabilno, bez znakova divergencije ili eksplodirajućeg gradijenta.

Testirane konfiguracije

Hiperparametarska eksploracija

1 Baseline

3 Veća arhitektura · 64-32

5 LR = 0.0005

7 64-32 + Dropout 0.3

2 Baseline + SMOTE ★

4 Bez Dropout regularizacije

6 LR = 0.01

8 64-32 + Drop 0.3 + LR 0.01

Cilj eksperimenata: ispitati robusnost modela i izolovati uticaj SMOTE, arhitekture, regularizacije i learning rate-a.

Poređenje 8 konfiguracija

Model	Accuracy	Recall	F1-score
Baseline	0.8833	0.7500	0.8571
★ SMOTE	0.9167	0.8214	0.9020
64-32	0.9167	0.8214	0.9020
No Dropout	0.8833	0.7857	0.8627
LR = 0.0005	0.8500	0.6786	0.8085
LR = 0.01	0.9167	0.8214	0.9020
Combined (64-32, Drop 0.3)	0.9167	0.8214	0.9020
Combined + LR 0.01	0.9000	0.8214	0.8846

Ključno zapažanje

Više modela u vrhu

Čak 4 konfiguracije dele najviše rezultate:

- SMOTE
- 64-32
- LR = 0.01
- Combined (64-32, Drop 0.3)

Zašto SMOTE?

Odabran je za finalni model jer direktno demonstrira **medicinski značaj** balansiranja klasa i ima najjasniju interpretaciju.

Kombinovanje pojedinačno uspešnih hiperparametara **ne garantuje** dodatno poboljšanje.

Najbolji model: SMOTE + MLP (32-16)

Accuracy

91.67%

Ukupna tačnost na test skupu

Precision

100%

0 lažno pozitivnih

Recall ★

82.14%

Ključna medicinska metrika

F1-score

90.20%

Balans P i R


Zašto baš ovaj model

Kriterijumi izbora

- Ostvaruje **najveći F1-score** među svim testiranim konfiguracijama
- Ostvaruje **najveći recall** — najvažnija metrika u medicinskoj dijagnostici
- **Nema lažno pozitivnih** predikcija (precision = 1.0)
- **Smanjuje broj lažno negativnih** slučajeva u odnosu na baseline
- Direktno demonstrira **pozitivan uticaj SMOTE** metode

Konfuziona matrica

SMOTE_32_16_dropout02_lr001



TN = 32 · zdravi tačno klasifikovani

FN = 5 · propušteni bolesnici

Šta smo naučili

Ograničenja

- ▶ Mali skup podataka (297 uzoraka)
- ▶ Veća arhitektura ne donosi poboljšanje
- ▶ Kombinacija jakih hiperparametara nije aditivna
- ▶ Ograničena generalizacija na druge populacije

Šta smo naučili

- ✓ Kvalitetna priprema podataka > složenija arhitektura
- ✓ SMOTE ima najveći pojedinačni efekat
- ✓ Za male skupove dovoljni su jednostavni MLP modeli
- ✓ Recall je medicinski relevantnija metrika od accuracy

Moguća unapređenja

- Veći skupovi podataka
- K-fold cross validation
- Ensemble modeli
- Explainable AI (SHAP, LIME)
- Integracija u sistem procene rizika

Konačni rezultat

SMOTE + MLP (32-16)

MLP neuronska mreža uspešno rešava problem predikcije srčanih oboljenja na strukturanim medicinskim podacima.

Accuracy

91.67%

Recall ★

82.14%

F1-score

90.20%